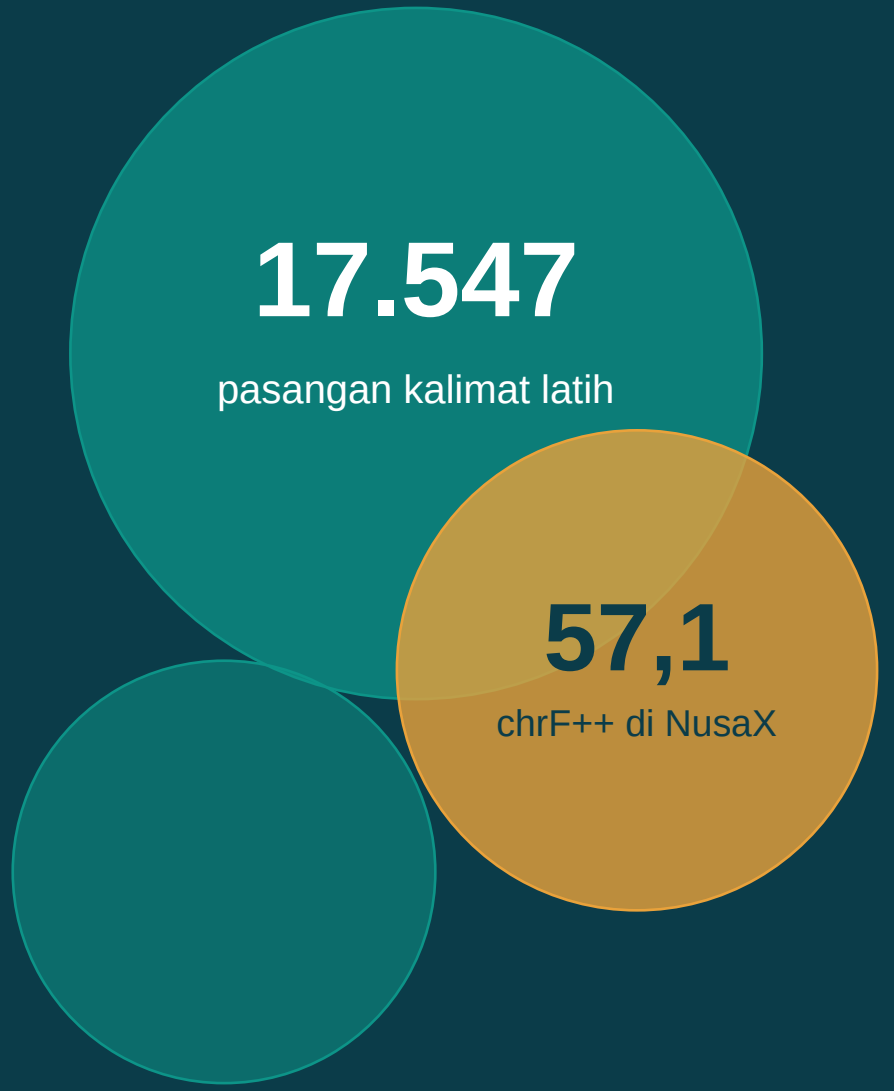
Penerjemah Bahasa Aceh ke Bahasa Indonesia

Korpus AcehX dan model NLLB hasil fine-tuning, lengkap dengan aplikasi lokal



Kelompok 2 · Proyek AcehX · Universitas Syiah Kuala · 23 Oktober 2026

TIM

Anggota tim Kelompok 2

AF	Andrie Fadhlullah Wahby
MM	M. Miqdad Ramadhan F
SR	Syaukas Rahmatillah
MK	Muhammad Khairul Ikhsan
MF	Mohammad Fawad Karimi
H	Habibi
M	Mutaib
MR	Muhammad Raza Adzani
MS	Muhammad Shiddiq

GAMBARAN

Proyek kami secara singkat

17.547

pasangan latih dari sembilan sumber

57,1

chrF++ di NusaX, naik dari 38,7

+36,9

kenaikan chrF++ pada syair hikayat

Data

Sembilan sumber: korpus terbuka, buku hasil pindai, skripsi, dan terjemahan tim. Sudah dibersihkan dan diperiksa.

Teknik

OCR, penyejajaran, augmentasi pivot, fine-tuning, serta perbandingan direct, transfer, dan neural.

Evaluasi

Tiga set uji yang tidak pernah dilatih, dinilai dengan BLEU, chrF, dan chrF++.

Aplikasi

Aplikasi lokal tanpa internet dengan panel kamus yang menandai arti kata terbaik.

GAMBARAN

Tujuan dan tahapan proyek

1. Sourcing

Menentukan asal bahan sebelum diolah

2. Normalisasi

Menyamakan ejaan dan bentuk teks

3. Screening

Memberi status KEEP, REVIEW, atau DROP

4. Capture

Memindai, OCR, dan mengetik ulang bahan cetak

Sasaran

- Minimal: terjemahan Aceh ke Indonesia
- Ideal: terjemahan dua arah
- Hasil berupa proof of concept (bukti kelayakan)

Setelah itu

Data dibagi menjadi data latih, validasi, dan uji. Lalu disiapkan data card untuk Atlas Data AI: asal data, isi, lisensi, dan cara pakai.

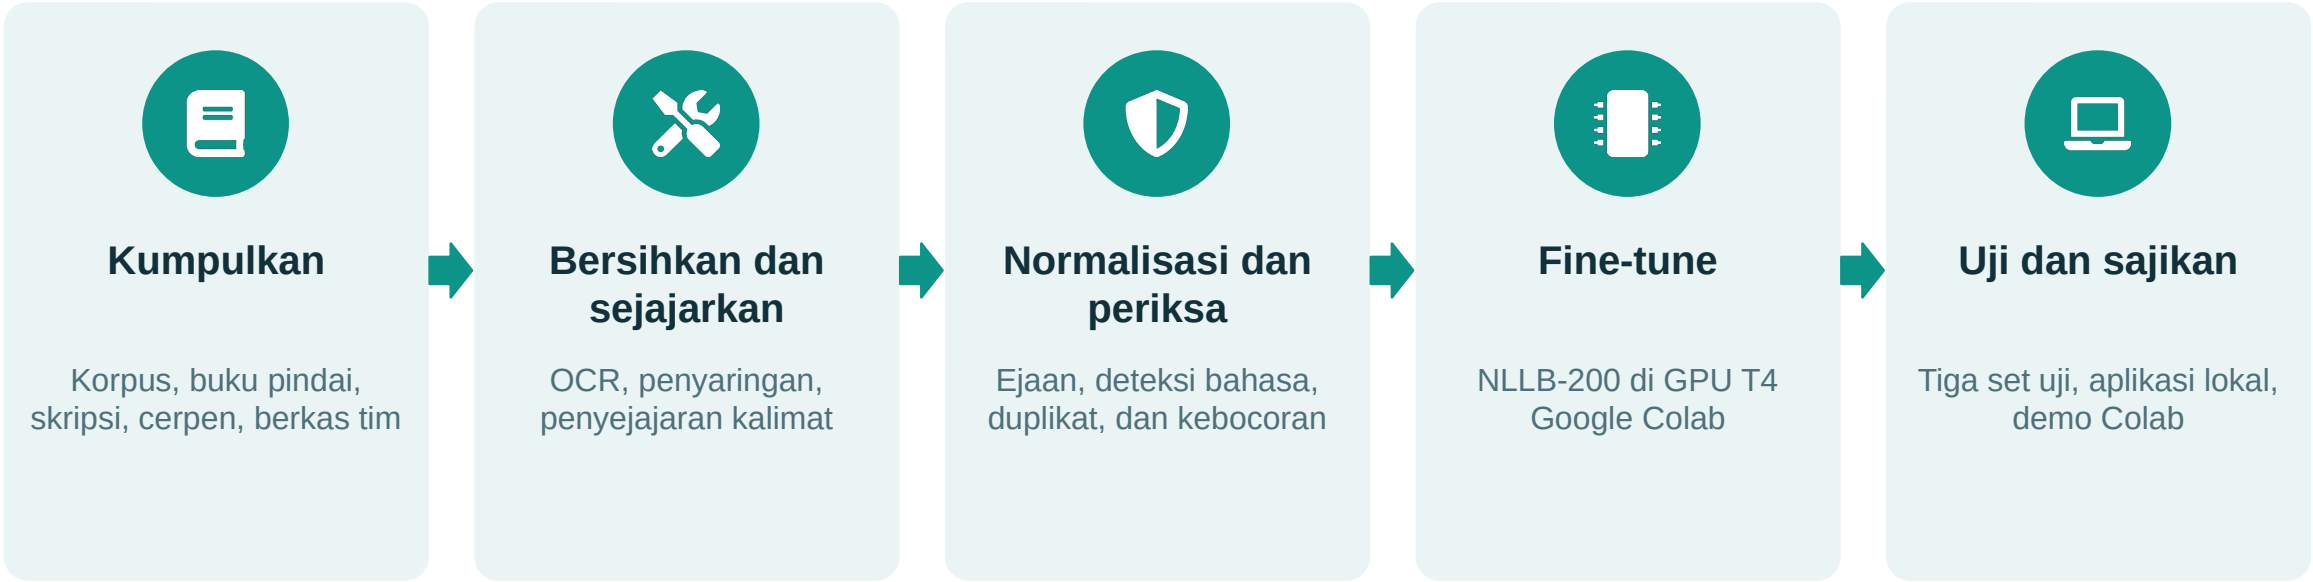
GAMBARAN

Teknik yang kami pakai

Teknik	Cara kerja di proyek kami	Bukti
Pendekatan direct	Cari arti tiap kata di daftar Kamus Aceh-Indonesia 1985 (5.260 kata). Urutan kata tetap.	chrF++ 35,5
Pendekatan transfer	Pecah awalan dan akhiran -jih, ganti 15 kata fungsi dengan aturan, lalu susun kalimat Indonesia.	chrF++ 39,2
Pandangan antarlingua	Encoder NLLB mengubah kalimat Aceh menjadi representasi bersama. Decoder menulis bahasa Indonesia.	Token terlihat di aplikasi
Terjemahan neural	NLLB-200 (600 juta parameter) di-fine-tune pada 17.547 pasangan, berhenti dini lewat skor validasi.	chrF++ 57,1 / BLEU 30,8
Augmentasi data	Terjemahan pivot: kalimat Aceh buatan manusia dan teks Inggris. NLLB menerjemahkan Inggris ke Indonesia.	± 5.700 pasangan
Disambiguasi	Arti kata di kamus diurutkan menurut kecocokan dengan terjemahan. Arti terbaik diberi tanda centang.	266 kata punya banyak arti

GAMBARAN

Dari sumber mentah ke aplikasi



Alat yang dipakai

PyMuPDF dan RapidOCR (buku pindai) · rapidfuzz dan datasketch (duplikat) · Hugging Face Transformers dan PyTorch (pelatihan) · sacreBLEU (penilaian) · Gradio (aplikasi) · Google Colab GPU T4

Dasar teori singkat

Transformer

Model dengan encoder dan decoder. Encoder membaca kalimat sumber. Decoder menulis kalimat tujuan dengan melihat konteks (Vaswani dkk., 2017).

NLLB-200

Model terjemahan Meta untuk sekitar 200 bahasa, termasuk bahasa Aceh (kode ace_Latn). Kami memakai versi distilled 600 juta parameter.

NusaX dan FLORES-200

NusaX: kalimat paralel untuk 10 bahasa daerah. FLORES-200: tolok ukur terjemahan dari Meta. Keduanya kami pakai untuk latih dan uji.

Datasheets for Datasets

Data harus punya catatan jelas: asal, isi, cara pengumpulan, dan lisensi. Prinsip ini kami terapkan pada korpus AcehX.

EVALUASI

Cara menilai terjemahan

BLEU

Menghitung kecocokan kelompok kata antara hasil model dan terjemahan manusia.

chrF

Menghitung kecocokan kelompok huruf. Cocok untuk bahasa dengan banyak imbuhan.

chrF++

chrF ditambah informasi kata. Ini skor utama kami.

Cara membaca skor

- Skala 0 sampai 100. Makin tinggi makin baik.
- BLEU 30,79 tidak berarti 30,79% kalimat benar.
- Kami juga memeriksa contoh keluaran, karena salah makna dan negasi tidak terlihat dari skor.

DATA

Data paralel yang kami kumpulkan

Sumber	Isi	Pasangan dipakai	Lisensi / asal
NusaX-MT	Terjemahan manusia Aceh–Indonesia (IndoNLP)	500 latih, 100 validasi, 400 uji	CC-BY-SA 4.0
FLORES-200	Terjemahan profesional kalimat gaya Wikipedia (Meta)	797 latih, 200 validasi, 1.012 uji	CC-BY-SA 4.0
Hikayat Abu Sammah	Syair dengan terjemahan, buku hasil pindai (Depdikbud)	1.432 latih, 79 validasi, 143 uji	Buku pemerintah, disebut sumbernya
Hikayat Malik Mawot	Syair dan terjemahan (Inayati, UIN Ar-Raniry, 2017)	350	Skripsi, disebut sumbernya
Terjemahan Al-Qur'an	Tgk. Mahjiddin Jusuf (Aceh) dan Kemenag (Indonesia)	5.466 ayat	Disebut sumbernya
Wikipedia (OPUS)	Kalimat artikel Aceh dan Indonesia yang sejajar	375 dari 557	CC-BY-SA 4.0
Pivot NLLB-Seed	Meta/OLDI: 6.193 kalimat Aceh buatan manusia dengan teks Inggris	± 5.700	CC-BY-SA 4.0
Terjemahan tim	Berkas Andrie (5.000 baris) dan lima cerpen (103 pasang)	2.798 dan 96	Hasil kerja tim

DATA

Korpus AcehX: isi berkas

Berkas	Unit	Kandidat pasangan
Corpus AcehX (TXT)	63.367	Belum ada terjemahan
Cerita (CSV)	11.103	103
Lagu dan puisi (CSV)	5.271	0
Berkas JSONL	5.000	4.146

Unit = baris TXT atau rekaman CSV/JSONL. Kandidat pasangan = kedua sisi teks terisi; belum berarti terjemahannya sudah divalidasi.

- Cerita: 11.103 kalimat, 103 di antaranya berpasangan
- Lagu: 6 koleksi, 3.675 larik. Puisi: 1 koleksi, 1.596 larik

63.346

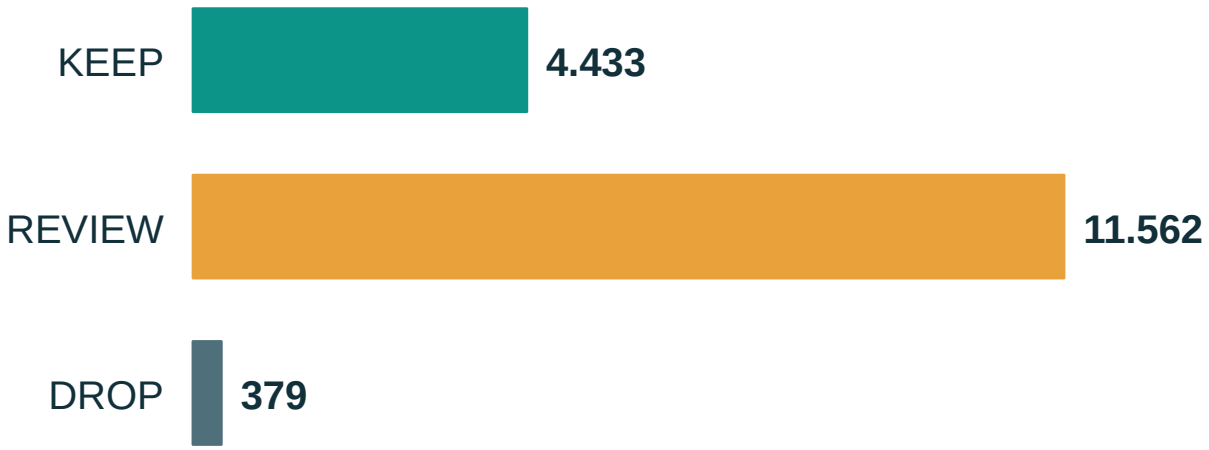
teks unik dari 63.367 baris TXT (21 duplikat)

15.995

teks unik dari 16.374 rekaman CSV

Status screening: KEEP, REVIEW, DROP

Status 16.374 rekaman CSV



- KEEP: lolos pemeriksaan awal
- REVIEW: perlu ditinjau lagi
- DROP: dikeluarkan, tetap disimpan untuk penelusuran

2,31%

duplikat (379 dari 16.374). Batas di brief: 5%

80

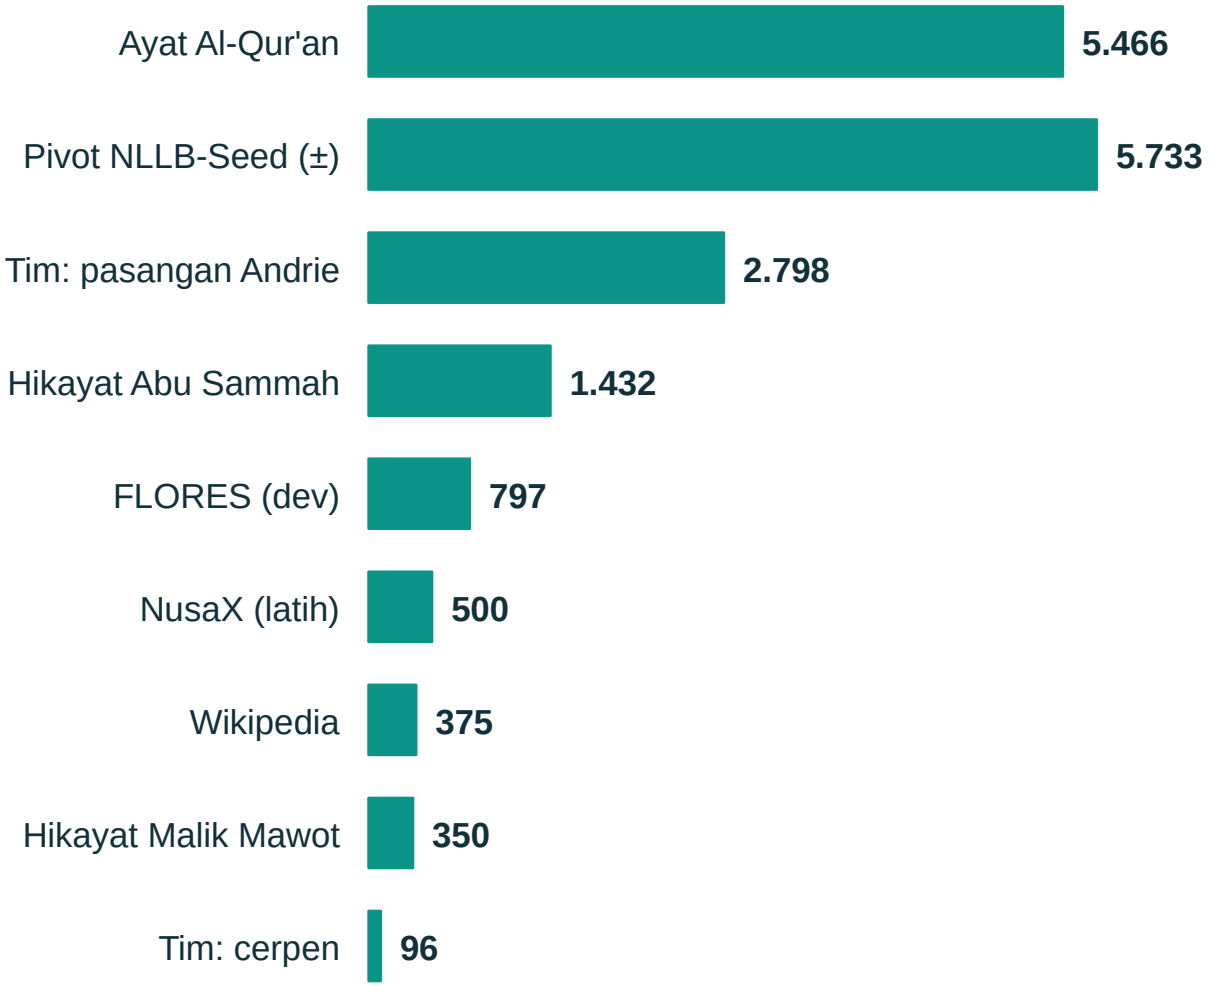
templat menghasilkan 10.000 unit cerita; partisi nanti dibuat per templat

Penutur

meninjau rekaman REVIEW: langkah berikutnya

DATA

Campuran data latih: 17.547 pasangan



379

validasi: 200 FLORES, 79 hikayat, 100 NusaX

Set uji (tidak dilatih)

400	NusaX
1.012	FLORES
143	Hikayat

17.618 kandidat menjadi 17.547 setelah 1 pasangan mirip dan 70 duplikat dibuang

DATA

Dari buku pindai ke pasangan kalimat

1. OCR setiap halaman dengan 300 dpi (RapidOCR)
2. Buang nomor halaman, judul, catatan kaki, dan baris yang kurang yakin
3. Gabungkan baris yang terpotong tata letak
4. Perbaiki huruf salah hasil OCR, hanya jika teks acuan membenarkannya
5. Sejajarkan bait Aceh dan bait Indonesia dengan pemrograman dinamis
6. Beri label KEEP atau REVIEW, tidak ada yang dihapus

11,3% → 0,8%

kata salah: teks bawaan PDF dibanding OCR kami (contoh yang diperiksa tangan)

1.856

pasangan bait hasil penyejajaran

1.654

pasangan berlabel KEEP (199 berlabel REVIEW)

40 dari 40

pasangan KEEP acak yang diperiksa tangan ternyata benar

DATA

Skripsi, cerpen, dan terjemahan tim

Hikayat Malik Mawot

1.030 baris syair dan terjemahan

350 pasangan dipakai

Catatan kaki dibuang. Tiap pasangan diperiksa kemiripan baris dan bahasa Acehnya.

Berkas tim (Andrie)

5.000 baris diterima

2.798 pasangan setelah dibersihkan

Baris dengan galat OCR berat, tanpa terjemahan, atau sama dengan set uji dibuang.

Lima cerpen

103 pasangan kalimat bernomor

96 pasangan dipakai

Tabel sudah disejajarkan manusia. Baris yang terlalu pendek atau kurang jelas dibuang.

AUGMENTASI DATA

Terjemahan pivot: ± 5.700 pasangan

Bahasa Aceh

6.193 kalimat buatan manusia (NLLB-Seed)

→

Bahasa Inggris

Arti yang sama, dari dataset yang sama

→

NLLB Inggris ke Indonesia

Arah terjemahan yang sangat kuat

→

Pasangan latih

Aceh manusia + Indonesia mesin, diberi label

Penyaringan sebelum pasangan dipakai

- 4 sampai 60 kata di tiap sisi
- Perbandingan jumlah kata kedua sisi antara 0,5 dan 2
- Sisi Aceh harus lolos deteksi bahasa
- Diperiksa agar tidak bocor ke set validasi dan uji

5.750
kandidat setelah disaring

5.733
pasangan dipertahankan sebelum digabung

Sisi Indonesia adalah hasil mesin, jadi asalnya dicatat di metadata.

Menyiapkan dan memeriksa teks

Normalisasi

Aturan sama untuk pelatihan dan aplikasi

- Unicode NFC dan tanda kutip lurus
- Ejaan lama: njang → nyang, djipeugot → jipeugot
- Tanda dua titik dibuang: löen → loen
- Teks asli selalu disimpan di samping teks normal

Deteksi bahasa

Model n-gram huruf (naive Bayes)

- Dilatih dari AcehX dan NusaX latih
- Bahasa Aceh dikenali 96–98%
- Bahasa Indonesia dikenali 99,5–100%
- Menyaring baris asing atau berisik

Kontrol duplikat

Kecocokan persis dan hampir sama

- Kunci cocok mengabaikan huruf besar, aksen, tanda baca, ejaan lama
- Hampir sama: kemiripan 90% atau lebih (rapidfuzz)
- MinHash-LSH terhadap AcehX (164.778 baris)
- Duplikat ditandai, tidak dibuang diam-diam

Menjaga ujian tetap jujur

1. Halaman uji dan validasi dijaga sebagai satu blok, jadi bait yang bersebelahan tidak terpisah
2. Pasangan latih yang sama dengan kalimat validasi atau uji dibuang, tanpa memandang huruf besar, aksen, tanda baca, dan ejaan lama
3. Pasangan latih yang 90% atau lebih mirip dengan kalimat uji dibuang
4. Skrip pelatihan menolak mulai jika masih ada satu kebocoran
5. Epoch terbaik dipilih dari validasi saja, tidak dari set uji

17.547
Latih

379
Validasi

1.555
Uji (400 + 1.012 + 143)

METODE

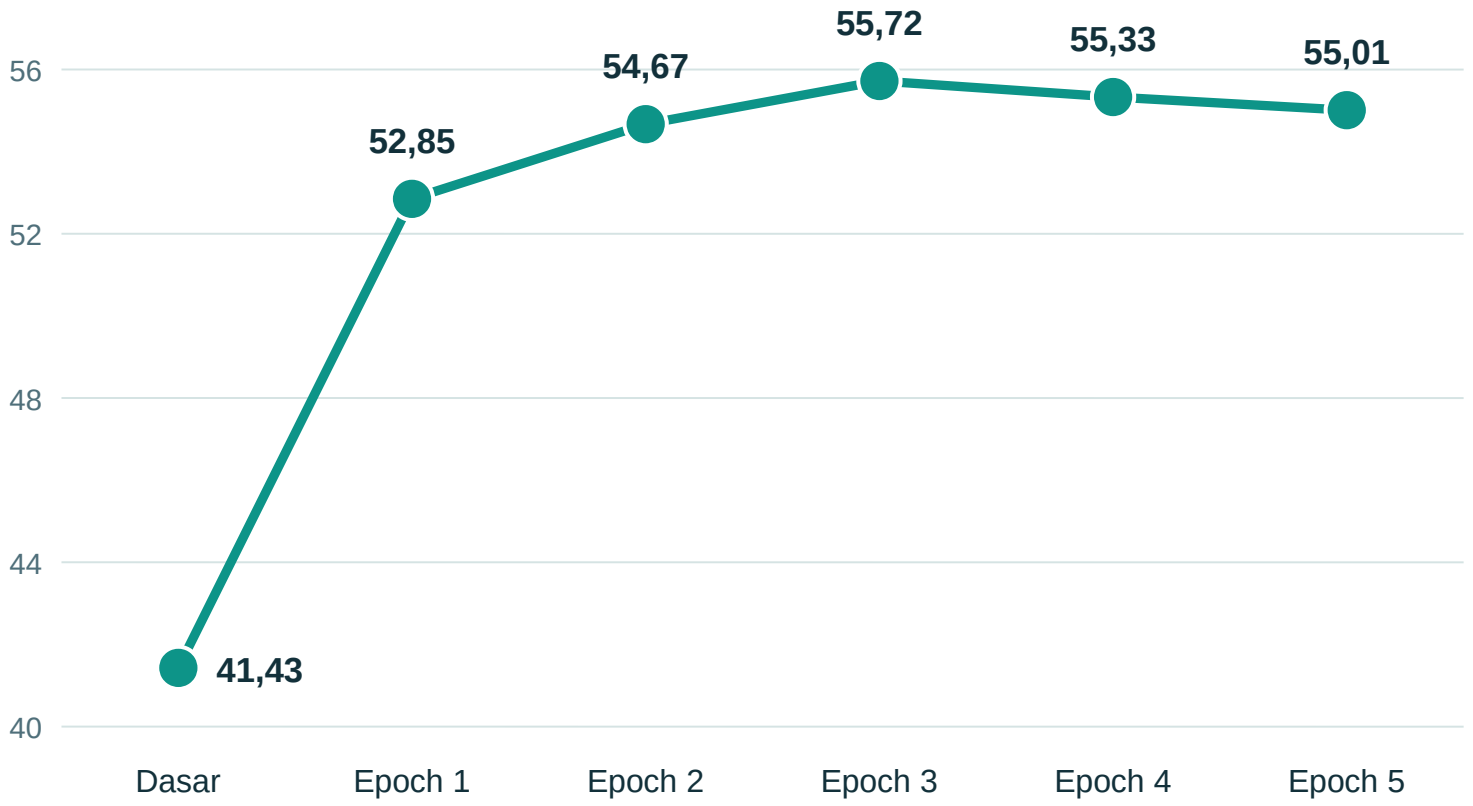
Model dan pengaturan pelatihan

Pengaturan	Nilai	Alasan
Model dasar	NLLB-200 distilled, 600 juta parameter	Sudah mengenal bahasa Aceh (ace_Latn)
Yang dilatih	Seluruh bobot	Menyesuaikan seluruh model dengan data kami
Optimizer	Adafactor, laju belajar 1e-4, pemanasan 10%	Hemat memori, muat di GPU T4 Colab
Batch dan panjang	8 pasangan, sampai 128 token	Muat di memori GPU
Label smoothing	0,1	Mengurangi terlalu percaya diri pada data kecil
Penghentian	Maksimal 10 epoch, sabar 2 epoch	Berhenti jika validasi tidak naik
Pemilihan model	Epoch terbaik menurut chrF++ validasi	Set uji tidak ikut memilih
Model tersimpan	Setengah presisi (FP16), 1,2 GB	Terjemahan sama, ukuran separuh

METODE

Proses pelatihan

chrF++ validasi per epoch



Epoch 3 dari 5

dipilih; berhenti setelah 2 epoch tanpa kenaikan

3,39 → 2,31

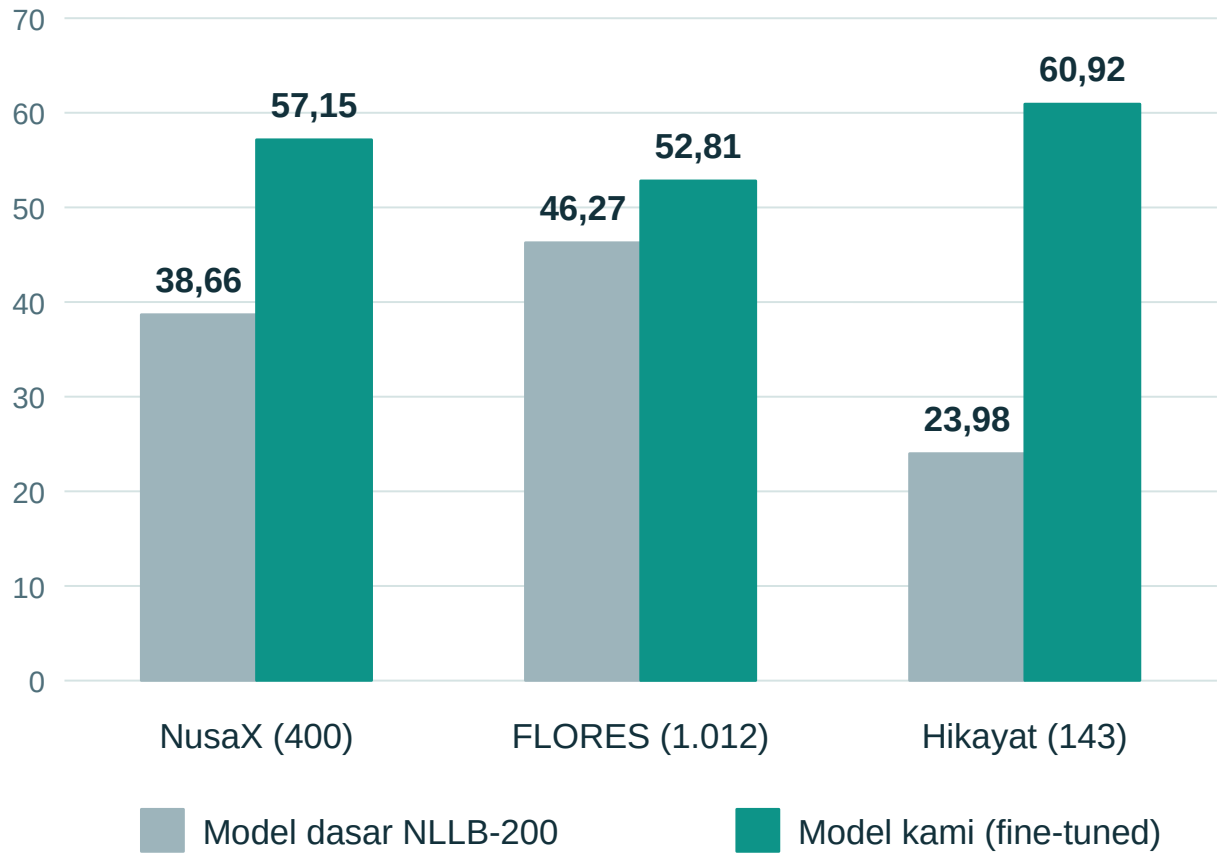
loss latih, epoch 1 sampai 5

GPU T4

Google Colab, 17.547 pasangan

Skor naik di semua set uji

chrF++ (makin tinggi makin baik)



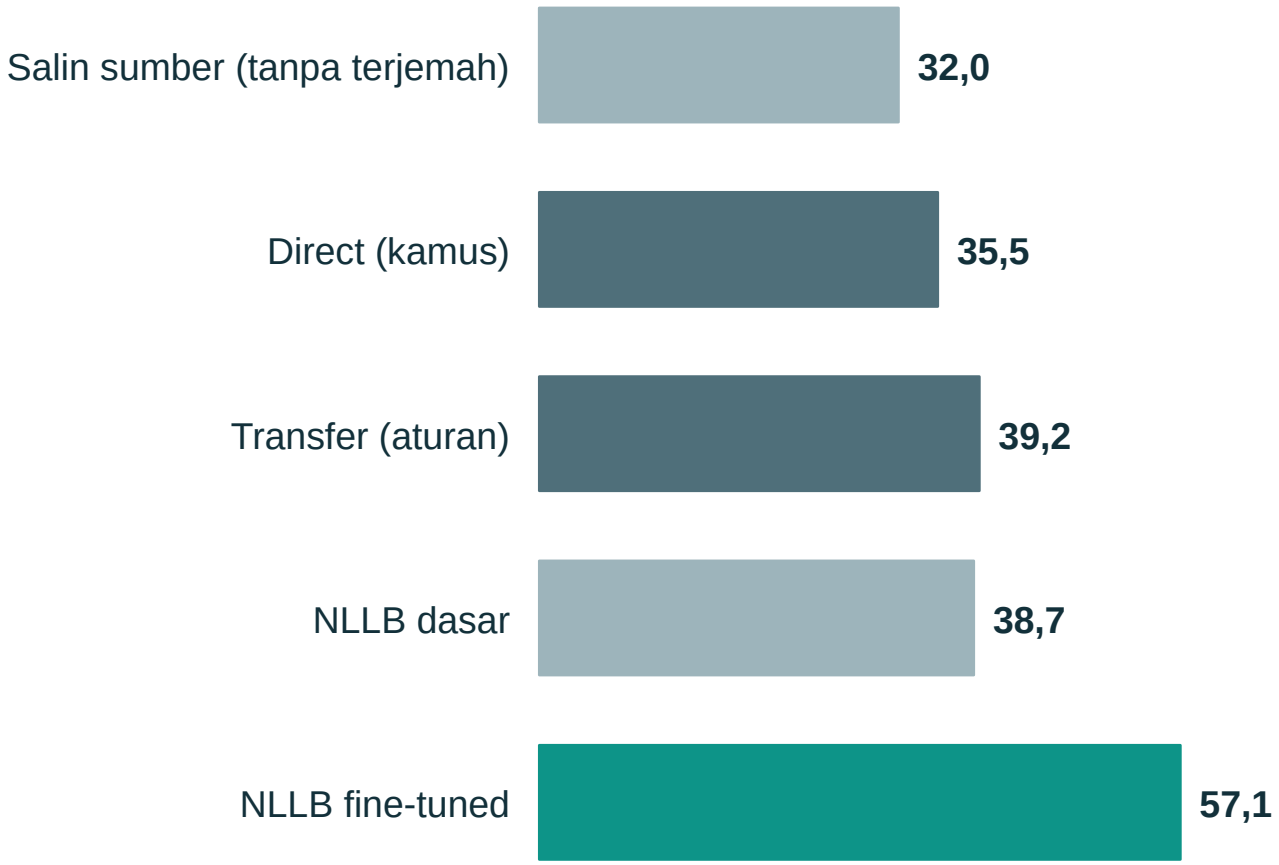
Set uji	BLEU	chrF	chrF++
NusaX	13,53 → 30,79	41,58 → 59,64	38,66 → 57,15
FLORES	21,31 → 27,32	48,74 → 55,05	46,27 → 52,81
Hikayat	2,68 → 35,94	26,84 → 63,02	23,98 → 60,92

Cara membaca

Tabel: model dasar → model kami. Kalimat uji tidak pernah dilatih dan tidak dipakai memilih model. Hikayat paling dekat dengan data syair kami; NusaX dan FLORES menunjukkan pemakaian sehari-hari.

Pendekatan klasik dan neural

chrF++ pada 400 kalimat uji NusaX



+3,5

Direct dibanding menyalin sumber

+3,7

Transfer dibanding direct

+17,9

Neural fine-tuned dibanding transfer

TEKNIK

Direct dan transfer lebih dekat

Pendekatan direct

- Cari tiap kata di daftar kamus 1985
- Ambil arti pendek pertama
- Urutan kata Aceh tetap
- Kata yang tidak ada dibiarkan

Pendekatan transfer

- Analisis: pecah awalan ji-, geu-, neu-, ta- dan akhiran -jih
- Transfer: 15 kata fungsi, mis. hana → tidak, nyang → yang, lon → saya
- Hasil: susun dan beri huruf kapital
- Tiap kata dipakai hanya jika NusaX mendukung (50%+ dari 20+ kalimat)

Contoh nyata dari set uji NusaX

Aceh	Toe ngon hotel lon dom	**Direct**	Toe meuteumee hotel padam bermalam
Transfer	Toe dengan hotel saya bermalam	**Acuan**	Dekat dengan hotel saya menginap

Pandangan antarlingua: ruang bersama



Satu model bersama

Semua bahasa melewati representasi yang sama. Ini versi yang dipelajari dari antarlingua buatan tangan.

Terlihat di aplikasi

Panel 'Cara kerja model' menampilkan token encoder dan decoder yang sebenarnya.

Dipilih lewat tag

Tag bahasa memilih sumber dan tujuan, jadi model yang sama bisa menerjemahkan ke dua arah.

TEKNIK

Disambiguasi berbasis kamus

1. Cari tiap kata Aceh di antara 5.260 kata dalam Kamus Aceh-Indonesia (1985)
2. Kumpulkan semua arti kata itu
3. Beri skor tiap arti menurut kata yang sama dengan terjemahan model, tanpa kata hubung umum
4. Beri tanda centang pada arti terbaik jika jelas unggul

Contoh

Gobnyan jak u keude

Terjemahan: Dia pergi ke toko

✓ **keude: kedai, toko …**

keude: endapan sisa masakan berkuah

5.260

kata di kamus

266

kata punya banyak arti

HASIL

Contoh terjemahan dari model

Aceh	**Lon jak u peukan uroe nyoe.**
Model kami	**Saya pergi ke pasar hari ini.**

Aceh	**Teuma troih le Abu Sammah, budak indah paraih rupa**
Model kami	**Lalu sampailah Abu Sammah, budak indah paras rupa**

Aceh	**Nyo beutoi, jih teungoh jaga warong.**		
Model kami	**Ini benar, dia sedang menjaga warung.**		
NLLB dasar	Ini benar, karena dia sedang menjaga warganya.	Acuan	Iya benar, dia sedang jaga warung.

Contoh: yang membaik dan yang dijaga

Membaik: arti kata

NusaX: "Nyo beutoi, jih teungoh jaga warong." Model dasar menulis "menjaga warganya". Model kami menulis "menjaga warung", sesuai acuan.

Perlu dijaga: konteks

NusaX: kalimat tentang aplikasi yang sedang dipelihara (jipeupah). Acuan membahas pemeliharaan, model kami memilih "menyewa".

Perlu dijaga: arah makna

FLORES (Shark Tank): penolakan pendanaan pada acuan berubah menjadi pemberian dana. Kesalahan seperti ini mengubah pesan utama.

Skor naik di semua set uji, tetapi arti kata, negasi, dan konteks tetap perlu diperiksa penutur bahasa Aceh.

APLIKASI

Aplikasi penerjemah

Lokal dan offline

Berjalan di 127.0.0.1:7860, tanpa internet setelah start pertama

Normalisasi sama

Teks dibersihkan persis seperti data latih

Kalimat demi kalimat

Tabel rincian: asli, normal, dan terjemahan

Cara kerja model

Token encoder dan decoder tiap terjemahan

Panel kamus

Arti kata dengan tanda centang pada arti terbaik

Panel akurasi

Skor uji tampil di samping penerjemah

Penerjemah Aceh → Indonesia

Bahasa Aceh

Lon jak u peukan uroe nyoe.

Bahasa Indonesia

Saya pergi ke pasar hari ini.

Terjemahkan · Translate

Cara kerja model · Kata per kata · Seberapa akurat?

Jalankan: ./run_app.sh (Mac) · run_app.bat (Windows) · notebook demo Colab dengan tautan publik · model di Hugging Face

KUALITAS

Bisa diulang, diuji, dan terdokumentasi

91

tes otomatis

Pemeriksaan kebocoran, normalisasi, OCR, penyejajaran, pelatihan, aplikasi

1

perintah per tahap

Tiap langkah jalan dari baris perintah acehid

Git

kode dan data di repositori

Daftar sumber dan lisensi di config/sources.csv

Alat

Python · PyTorch · Transformers 5.19 · sentencepiece · Gradio 6.29 · PyMuPDF · RapidOCR · rapidfuzz · datasketch · sacreBLEU · Google Colab

Bantuan AI

Kami memakai Claude, asisten AI, untuk membantu menulis banyak kode. Tim menentukan sumber data, aturan pembagian data, dan evaluasi, menjalankan pelatihan, serta memeriksa hasilnya.

Lisensi dan sumber

Model

Bobot NLLB-200 berlisensi CC-BY-NC 4.0, jadi model kami untuk penelitian dan pengajaran, bukan komersial.

Data terbuka

NusaX, FLORES, NLLB-Seed, dan Wikipedia berlisensi CC-BY-SA 4.0 dan disebut penulisnya.

Buku dan skripsi

Depdikbud (Hikayat Abu Sammah), Inayati (Hikayat Malik Mawot), Kemenag dan Tgk. Mahjiddin Jusuf (Al-Qur'an), Balai Bahasa Aceh (Kamus Budaya).

Daftar sumber

Tiap sumber, lisensinya, dan cara memakainya dicatat di config/sources.csv. Status lisensi sebagian sumber masih dikonfirmasi.

KESIMPULAN

Hasil kami dan langkah berikutnya

Yang sudah kami capai

- Audit korpus AcehX dan 17.547 pasangan latih dari sembilan sumber
- Fine-tuning NLLB-200: chrF++ NusaX 38,7 → 57,1, FLORES 46,3 → 52,8, hikayat 24,0 → 60,9
- Perbandingan direct, transfer, dan neural di set uji yang sama
- Augmentasi pivot dan disambiguasi kamus
- Aplikasi lokal dengan tampilan encoder dan decoder

Langkah berikutnya

- Tinjauan penutur untuk pasangan REVIEW dan terjemahan baru
- Uji ablasi: latih dengan dan tanpa tiap sumber, beberapa seed
- Kunci manifest dan konfigurasi agar mudah diulang
- Lengkapi dokumentasi lisensi dan data card Atlas Data AI
- Perluas augmentasi dengan back-translation dan versi aplikasi online

Rujukan dari makalah kami

1 Vaswani dkk., "Attention Is All You Need", NeurIPS, 2017.

2 NLLB Team dkk., "No Language Left Behind: Scaling Human-Centered Machine Translation", 2022.

3 Winata dkk., "NusaX: Multilingual Parallel Sentiment Dataset for 10 Indonesian Local Languages", EACL, 2023.

4 Papineni dkk., "Bleu: a Method for Automatic Evaluation of Machine Translation", ACL, 2002.

5 Popović, "chrF: character n-gram F-score for automatic MT evaluation", WMT, 2015; "chrF++: words helping character n-grams", WMT, 2017.

6 Post, "A Call for Clarity in Reporting BLEU Scores", WMT, 2018.

7 Gebru dkk., "Datasheets for Datasets", Communications of the ACM, 2021.

8 Meta AI, model card facebook/nllb-200-distilled-600M, Hugging Face.

Terima kasih

Pertanyaan dan diskusi



Kode dan data: github.com/Mutaib-yye/aceh_code